

INFORME TÉCNICO

Infraestructura de Datos en la Nube para Análisis de Capturas Pesqueras Globales

The Sea Around Us — Pipeline AWS: S3 · Glue · Athena

Sistemas Intensivos en Datos — 2026-1 · Universidad EAFIT

Fecha de elaboración: 28 de May de 2026

Integrante	Responsabilidad Principal
Alejandro Sepúlveda	Infraestructura S3 e ingestión de datos
Samuel Aristizabal	ETL, limpieza y catálogo de datos (AWS Glue)
Gabriela Lucía Martínez	Consultas Athena y capa de visualización

1. Introducción

The Sea Around Us es un proyecto de investigación global con sede en la Universidad de British Columbia (UBC) que recopila y analiza información científica sobre las pesquerías y los ecosistemas marinos del mundo. Este informe documenta el diseño, implementación y resultados de la infraestructura de datos en la nube construida sobre AWS para analizar datos históricos de capturas pesqueras del período 1950–2018.

El pipeline cubre tres etapas principales: **ingestión** de archivos CSV en Amazon S3, **transformación y catalogación** mediante AWS Glue, y **análisis** con Amazon Athena. La solución fue diseñada siguiendo principios de escalabilidad, bajo costo operativo y separación de responsabilidades entre integrantes del equipo.

1.1 Objetivos

- Construir un pipeline de ingestión, transformación y análisis de datos pesqueros sobre AWS.
- Implementar una arquitectura de capas (raw / processed) con almacenamiento eficiente en S3.
- Automatizar la catalogación de esquemas mediante AWS Glue Crawlers.
- Habilitar consultas analíticas SQL serverless sobre los datos procesados con Amazon Athena.
- Garantizar escalabilidad al dataset global completo de The Sea Around Us.

2. Conjuntos de Datos

Se trabajaron tres archivos CSV descargados del sitio oficial de The Sea Around Us (seaaroundus.org). Todos están en codificación UTF-8 y cubren el período 1950–2018.

Archivo	Descripción	Filas
SAU-GLOBAL-1-v48-0.csv	Capturas en toda el área de alta mar global	561 675
SAU-HighSeas-71-v48-0.csv	Capturas en el Pacífico Central Occidental (próx. a Fiyi)	26 720
SAU-EEZ-242-v48-0.csv	Capturas en la Zona Económica Exclusiva (ZEE) de Fiyi	27 049

Tabla 1. Archivos fuente del proyecto.

2.1 Esquemas de columnas por dataset

Dataset global (SAU-GLOBAL-1)

Columna	Tipo	Descripción
year	int	Año de la captura
fishing_entity	string	País o entidad pesquera
fishing_sector	string	Sector: Industrial, Artesanal, Subsistence, Recreational
catch_type	string	Tipo de captura: Landings, Discards
reporting_status	string	Reported o Unreported
gear_type	string	Arte de pesca utilizado
end_use_type	string	Uso final del producto
tonnes	double	Toneladas capturadas
landed_value	double	Valor estimado en USD (base 2010)

Tabla 2. Esquema de la tabla global.

Dataset Pacífico Central Occidental (SAU-HighSeas-71)

Columna	Tipo	Descripción
area_name	string	Nombre del área de alta mar
area_type	string	Tipo de área (high_seas)
year	int	Año de la captura
scientific_name	string	Nombre científico de la especie
common_name	string	Nombre común de la especie
functional_group	string	Grupo funcional ecológico
commercial_group	string	Grupo comercial
fishing_entity	string	País o entidad pesquera
fishing_sector	string	Sector de pesca
catch_type	string	Tipo de captura
reporting_status	string	Reported o Unreported
gear_type	string	Arte de pesca utilizado
end_use_type	string	Uso final del producto
tonnes	double	Toneladas capturadas
landed_value	double	Valor estimado en USD (base 2010)

Tabla 3. Esquema de la tabla highseas.

Dataset ZEE de Fiji (SAU-EEZ-242)

Columna	Tipo	Descripción
area_name	string	Nombre del área (Fiji)
area_type	string	Tipo de área (eez)
data_layer	string	Tipo de dato (Reconstructed domestic catch, etc.)
uncertainty_score	int	Puntaje de incertidumbre de la reconstrucción (0–4)
year	int	Año de la captura
scientific_name	string	Nombre científico de la especie
fish_name	string	Nombre común de la especie
functional_group	string	Grupo funcional ecológico
commercial_group	string	Grupo comercial
country	string	País que realizó la captura
fishing_sector	string	Sector de pesca
catch_type	string	Tipo de captura
reporting_status	string	Reported o Unreported
gear_type	string	Arte de pesca utilizado
end_use_type	string	Uso final del producto
tonnes	double	Toneladas capturadas
landed_value	double	Valor estimado en USD (base 2010)

Tabla 4. Esquema de la tabla eez (campos adicionales respecto a global).

3. Arquitectura del Pipeline

La arquitectura sigue el patrón de capas *raw / processed* (variante Medallion), usando exclusivamente servicios serverless o administrados de AWS para eliminar la necesidad de gestionar servidores o clústeres.

Etapas	Servicio / Componente	Descripción
1. Fuente	searroundus.org	3 archivos CSV descargados manualmente
2. Ingestión	Amazon S3 — capa raw	raw/global/ · raw/highseas/ · raw/eez/
3. Transformación	AWS Glue Jobs (ETL)	Normalización · casteo · manejo de nulos → Parquet
4. Almacenamiento	Amazon S3 — capa processed	Formato Parquet, compresión Snappy, particionado por year
5. Catalogación	AWS Glue Crawlers + Data Catalog	Base de datos searroundus_db con tablas: global, highseas, eez
6. Análisis	Amazon Athena	SQL serverless sobre S3; resultados a s3://.../query-results/
7. Visualización	QuickSight / Python	Series de tiempo, top N, comparativas alta mar vs. ZEE

Tabla 5. Etapas del pipeline de datos.

3.1 Estructura del bucket S3

Se usa un único bucket **searroundus-data-eafit** con prefijos que separan las capas. Esta decisión simplifica la gestión de permisos IAM y reduce el overhead de configuración frente a la alternativa de múltiples buckets.

```
s3://searroundus-data-eafit/raw/global/ ← CSV original alta mar global
s3://searroundus-data-eafit/raw/highseas/ ← CSV original Pacífico Central Occidental
s3://searroundus-data-eafit/raw/eez/ ← CSV original ZEE Fiyi
s3://searroundus-data-eafit/processed/global/ ← Parquet particionado por year
s3://searroundus-data-eafit/processed/highseas/ ← Parquet particionado por year
s3://searroundus-data-eafit/processed/eez/ ← Parquet particionado por year
s3://searroundus-data-eafit/query-results/ ← Resultados de consultas Athena
```

3.2 Jobs de AWS Glue

Cada dataset tiene su propio Glue Job independiente. Esta separación permite ejecutarlos en paralelo, facilita el mantenimiento individual y aísla los errores de transformación de un archivo respecto a los otros.

Job	Entrada (S3)	Salida (S3)	Partición
clean_global	raw/global/	processed/global/	year
clean_highseas	raw/highseas/	processed/highseas/	year
clean_eez	raw/eez/	processed/eez/	year

Tabla 6. Jobs de Glue y rutas correspondientes.

Las transformaciones aplicadas en todos los Jobs son:

- Normalización de nombres de columnas a **snake_case**.
- Casteo explícito de tipos: **year** → **int**, **tonnes** → **float**, **landed_value** → **float**.
- Identificación y tratamiento de nulos en columnas críticas (tonnes, landed_value, fishing_entity).
- Escritura del resultado en **formato Parquet con compresión Snappy**.
- Particionado por **year** (68 particiones: 1950–2018).

4. Catalogación y Capa de Consultas

4.1 AWS Glue Data Catalog

Los Crawlers de Glue inspeccionan los datos Parquet en la capa *processed* e infieren automáticamente el esquema de cada tabla, registrándolo en la base de datos **searoundus_db** del Data Catalog. Athena usa este catálogo para resolver nombres de columnas y tipos antes de ejecutar cualquier consulta.

Tabla en el catálogo	Origen en S3	Crawlers ejecutados
global	processed/global/	Crawler-global
highseas	processed/highseas/	Crawler-highseas
eez	processed/eez/	Crawler-eez

Tabla 7. Tablas del Glue Data Catalog.

4.2 Amazon Athena

Athena ejecuta consultas SQL estándar (compatible con Presto/Trino) directamente sobre los archivos Parquet en S3, sin necesidad de cargar los datos en ningún motor de base de datos. Gracias al particionado por *year*, las consultas que filtran por rango temporal solo leen las particiones relevantes (**partition pruning**), reduciendo significativamente el volumen escaneado y el costo por consulta.

Configuración de Athena:

- Workgroup: default (o workgroup propio del proyecto).
- Output location: s3://searoundus-data-eafit/query-results/
- Base de datos activa: searoundus_db

4.3 Consultas planificadas

Las siguientes consultas se ejecutarán tanto en la fase exploratoria como en la generación del reporte final:

#	Consulta	Tablas involucradas
1	Top 10 entidades pesqueras con mayor captura total (toneladas)	global
2	Tendencia histórica de capturas en la ZEE de Fiya (1950–2018)	eez
3	Comparación capturas en alta mar vs. ZEE — Pacífico Central Occidental	highseas, eez
4	Distribución por fishing_sector (industrial vs. subsistencia) en ZEE Fiya	eez
5	Porcentaje de capturas reported vs. unreported por fuente de datos	global, highseas, eez
6	Top 5 especies (scientific_name) más capturadas por década en ZEE Fiya	eez
7	Evolución del valor económico total (landed_value) por año — dataset global	global

Tabla 8. Consultas planificadas para Athena.

5. Seguridad y Permisos IAM

Se usa un único IAM Role con permisos de mínimo privilegio, asignado a los Glue Jobs y referenciado desde Athena. No se otorgan permisos sobre otros buckets ni servicios fuera del alcance del proyecto.

Servicio	Permisos
Amazon S3	s3:GetObject, s3:PutObject, s3:ListBucket — solo sobre el bucket del proyecto
AWS Glue	glue:GetDatabase, glue:GetTable, glue:CreateTable, glue:UpdateTable
Amazon Athena	athena:StartQueryExecution, athena:GetQueryResults

Tabla 9. Permisos IAM por servicio.

6. Escalabilidad y Decisiones de Diseño

El diseño actual trabaja con tres archivos de una región específica (Fiyi y su entorno). El dataset completo de The Sea Around Us abarca todas las regiones oceánicas del mundo, lo que implica un volumen significativamente mayor de archivos y registros. Las siguientes decisiones garantizan que la solución escale sin cambios estructurales.

Decisión	Alternativa considerada	Justificación
Parquet en capa processed	CSV en capa processed	Menor costo en Athena, lectura columnar, mejor compresión
Particionado por year	Sin particionado	Partition pruning: Athena solo lee particiones relevantes
Un Job de Glue por archivo	Un único Job para los tres	Facilita mantenimiento, permite ejecución paralela, aísla errores
Un bucket con prefijos	Un bucket por capa	Simplifica permisos IAM, reduce overhead de configuración
Athena serverless	Redshift o RDS	Sin infraestructura fija, costo por consulta, integración nativa con S3

Tabla 10. Registro de decisiones de diseño.

6.1 Estrategia de particionado para el dataset completo

Al incorporar todas las regiones oceánicas del mundo, se recomienda agregar una partición por **region** o **area_name** antes de la partición por **year**, produciendo la estructura *region=X/year=Y/*. Esto permite que las consultas filtradas por región y año sean especialmente eficientes.

6.2 Estimación de costos — dataset global completo

Para el dataset completo (~200 archivos CSV, estimado ~10 GB en crudo):

Servicio	Estimación	Notas
Amazon S3	< USD 0.25/mes	Con compresión Parquet el volumen baja a ~2 GB
AWS Glue	USD 1–5 total	Costo único de transformación (ejecución de Jobs)
Amazon Athena	< USD 0.25/consulta	USD 5/TB escaneado; Parquet + particionado → < 50 MB por consulta típica

Tabla 11. Estimación de costos referenciales en AWS.

7. Estado de Avance del Proyecto

A continuación se resume el estado de las tareas por integrante, de acuerdo con el archivo *TODO.md* del repositorio.

Integrante	Bloque	Estado
Alejandro Sepúlveda	1.1 Configurar bucket S3	✓ Completado
Alejandro Sepúlveda	1.2 Descargar y validar archivos CSV	✓ Completado
Alejandro Sepúlveda	1.3 Subir CSV a S3	✓ Completado
Alejandro Sepúlveda	1.4 Documentar arquitectura y escalabilidad	✓ Completado
Samuel Aristizabal	2.1 Job Glue — SAU-GLOBAL-1	■ Pendiente
Samuel Aristizabal	2.2 Job Glue — SAU-HighSeas-71	■ Pendiente
Samuel Aristizabal	2.3 Job Glue — SAU-EEZ-242	■ Pendiente
Samuel Aristizabal	2.4 Configurar Glue Data Catalog	■ Pendiente
Samuel Aristizabal	2.5 Notificar a Gabriela	■ Pendiente
Gabriela L. Martínez	3.1 Configurar Athena	■ Pendiente
Gabriela L. Martínez	3.2 Consultas exploratorias	■ Pendiente
Gabriela L. Martínez	3.3 Consultas para informe final	■ Pendiente
Gabriela L. Martínez	3.4 Visualizaciones y reporte analítico	■ Pendiente
Equipo completo	Prueba de integración end-to-end	■ Pendiente
Equipo completo	Informe técnico final y sustentación	■ Pendiente

Tabla 12. Estado de avance por tarea y responsable.

8. Conclusiones

- La arquitectura raw/processed sobre Amazon S3 proporciona una base sólida y reproducible para el análisis de datos pesqueros a escala global, con separación clara entre datos originales y datos transformados.
- El uso de **formato Parquet con particionado por year** es la decisión de mayor impacto en costo y rendimiento: permite partition pruning en Athena y reduce el volumen de datos escaneados en más de un 90 % frente a CSV sin particionar.
- La separación de Jobs de Glue por dataset facilita el mantenimiento independiente, la depuración de errores y la eventual paralelización del procesamiento.
- La solución es escalable al dataset completo de The Sea Around Us sin cambios estructurales, únicamente parametrizando los Jobs existentes y ajustando la estrategia de particionado a region/year.
- El modelo de costos serverless (S3 + Glue + Athena) elimina la necesidad de infraestructura fija y hace viable el proyecto para equipos académicos con presupuesto reducido.

